

Maths appliquées à la Data-Science

Analyse des sentiments Twitter et résultats électoraux (US 2020)

Peut-on prédire le vote via les réseaux sociaux ?


Présenté par ADAMI Josué, B3 Data/IA - Janvier 2026



L'Écho Numérique des Élections Américaines

Cette étude explore la relation entre l'opinion publique exprimée sur Twitter et les résultats de l'élection présidentielle américaine de 2020. J'ai analysé 4.1 millions de tweets contenant les hashtags #donaldtrump et #joebiden pour déterminer si les sentiments exprimés peuvent prédire l'issue du vote.

- Analyse des sentiments sur Twitter pendant l'élection présidentielle américaine de 2020.
- Corrélation entre la polarité des tweets et les résultats électoraux réels.
- Exploration des variations géographiques des sentiments.



Ma Boîte à Outils Technologique



Data Science

J'ai utilisé **Pandas** et **NumPy** pour la manipulation des données, et **Matplotlib** ainsi que **Seaborn** pour les visualisations.



Traitement du Langage Naturel (NLP)

TextBlob a été essentiel pour l'analyse des sentiments, **Langdetect** pour la détection de la langue, et **NLTK** pour le traitement linguistique. J'ai également généré des nuages de mots.



Cartographie Spatiale

Pour la visualisation géographique, **GeoPandas** et **Shapely** ont été employés, avec une projection **EPSG:5070** pour une précision optimale.



Le volume total de données traitées s'élève à 4.1 millions de tweets, dont 2.3 millions pour Trump et 1.8 million pour Biden.

Le Processus de Transformation des Données



1. Chargement des Données

Importation des 4.1 millions de tweets bruts collectés durant la période électorale.



2. Filtrage Stratégique

Sélection des tweets originaux des États-Unis, publiés avant la fermeture des bureaux de vote, et rédigés en anglais.



3. Nettoyage Préalable

Suppression des mentions (@utilisateur), des hashtags (#sujet), et des URLs pour isoler le contenu textuel pertinent.



4. Suppression des Mots Vides

Utilisation de la bibliothèque **NLTK** pour éliminer les "stop words" (mots courants sans valeur sémantique forte).





5. Analyse de Sentiments

Application de **TextBlob** pour attribuer un score de polarité à chaque tweet, évaluant son orientation positive, négative ou neutre.

KOMETNCS

L'analyse des sentiments a révélé que la majorité des tweets étaient neutres, avec une polarisation modérée. La polarité des tweets varie de -1 (très négatif) à +1 (très positif), avec 0 indiquant un sentiment neutre. La subjectivité mesure si le tweet exprime un fait (0) ou une opinion (1).



La Régression Linéaire : Mon Modèle Prédictif



Conception "From Scratch"

J'ai implémenté mon propre modèle de régression linéaire, sans recourir à des bibliothèques préexistantes, afin de maîtriser chaque aspect du calcul.

$$+=x$$

Formule Clé

$$m = \frac{n \times \sum(xy) - \sum x \times \sum y}{n \times \sum(x^2) - (\sum x)^2}$$

Cette formule est utilisée pour calculer la pente de la droite de régression, où 'm' représente la pente.



Coefficient R²

Le coefficient R² (coefficient de détermination) a été utilisé pour évaluer la qualité de l'ajustement de mon modèle, mesurant la proportion de la variance des votes explicable par la polarité des tweets.



Objectif de l'Analyse

L'objectif principal était d'établir une corrélation entre la polarité moyenne des tweets par État et le pourcentage réel des votes obtenus par chaque candidat dans ces mêmes États.



Corrélations : Twitter et l'Urne

Corrélation Faible

Mon analyse a révélé une corrélation **faible** entre la polarité des sentiments sur Twitter et les résultats des votes réels ($R^2 < 0.3$). Cela suggère que Twitter ne constitue pas un indicateur fiable de l'intention de vote.

États Gagnés vs. Perdus

Aucune différence significative n'a été observée dans les sentiments Twitter entre les États où un candidat a gagné et ceux où il a perdu. Les dynamiques de plateforme ne reflètent pas les nuances des préférences électorales.

Le Sentiment n'est pas le Vote

La conclusion principale est claire : les sentiments exprimés sur Twitter ne prédisent **pas** efficacement les résultats électoraux. L'expression en ligne est distincte de l'action de voter.

Paysage des Sentiments : Une Perspective Géographique



Polarité Moyenne par État

Des cartes choroplèthes, générées avec **GeoPandas**, ont visualisé la polarité moyenne des tweets pour Trump et Biden dans chaque État. Bien qu'il y ait des variations, elles ne sont pas directement corrélées avec les résultats électoraux.



Subjectivité et Résultats Électoraux

Des cartes similaires ont été créées pour la subjectivité moyenne et les résultats officiels. J'ai observé des patterns géographiques partiellement cohérents, mais l'analyse de sentiment seule ne suffit pas pour la prédiction.

Twitter vs Vote : Les Limites d'une Prédiction



Biais Démographique

Les utilisateurs de Twitter sont souvent plus jeunes, urbains et éduqués, ne représentant pas fidèlement l'ensemble de l'électorat.



Amplification Algorithmique

Les algorithmes de la plateforme ont tendance à favoriser les contenus polarisants, ce qui peut fausser la perception de l'opinion générale.



Bots et Manipulation

La présence de comptes automatisés (bots) et de campagnes de désinformation peut significativement influencer le volume et la tonalité des tweets.



Expression ≠ Action

L'acte de tweeter est une forme d'expression, mais il ne se traduit pas nécessairement par une intention ou une action de vote concrète.

Synthèse : Le Rôle de Twitter en Politique

Ce que Twitter capture avec succès



- **Énergie Émotionnelle** : Twitter est un baromètre efficace de l'intensité émotionnelle et de l'engagement autour des campagnes électorales.
- **Patterns Géographiques** : Il révèle des tendances géographiques dans la discussion politique, bien que celles-ci ne soient pas directement prédictives.

Les Limites de Twitter comme Outil Prédicatif



- **Non Représentatif** : La plateforme ne constitue pas un échantillon représentatif de la population votante, en raison de ses biais inhérents.
- **Sentiments $\neq$ Votes** : Les sentiments exprimés en ligne ne sont pas un indicateur fiable de l'intention de vote réelle.

Twitter doit être considéré comme un outil **complémentaire** pour comprendre les dynamiques politiques, mais **non prédictif** des résultats électoraux.

Leçons Apprises et Horizons Futurs

Compétences Acquises

Cette étude a permis de renforcer mes compétences en **Big Data** (gestion de 4.1M de tweets), en **NLP** (analyse des sentiments, nettoyage de texte), en **Régression Linéaire** (implémentation "from scratch"), et en **Cartographie Spatiale** (GeoPandas).

Axes d'Amélioration

Pour des recherches futures, il serait pertinent d'intégrer une **Analyse Temporelle** des tweets, d'explorer des modèles de **Machine Learning** plus avancés (ex: Random Forest), et d'implémenter des méthodes de **Détection de Bots** pour affiner les données.

MERCI !

Des Questions ?

