

Maths appliquées à la Data-Science

1. Analyse des sentiments Twitter et résultats électoraux (US 2020)

Peut-on prédire le vote via les réseaux sociaux ?

Présenté par ADAMI Josué, B3 Data/IA - Janvier 2026




2. L'Écho Numérique des Élections Américaines

Cette étude explore la relation entre l'opinion publique exprimée sur Twitter et les résultats de l'élection présidentielle américaine de 2020. J'ai analysé 4.1 millions de tweets contenant les hashtags #donaldtrump et #joebiden.

Mon étude s'articule autour de **trois objectifs principaux** :

- Réaliser une analyse des sentiments sur Twitter pendant l'élection présidentielle américaine de 2020.
- Chercher une corrélation entre la polarité des tweets et les résultats électoraux réels.
- Explorer les variations de sentiments à travers les 50 états.



3. Technos utilisées :



Data Science

J'ai utilisé **Pandas** manipulation des données et **NumPy** pour appliquer les formules, et **Matplotlib** ainsi que **Seaborn** pour les visualisations.



Traitement du Langage Naturel (NLP)

TextBlob a été essentiel pour l'analyse des sentiments (polarité), **Langdetect** pour la détection de la langue, et **NLTK** pour supprimer les stop words.



Cartographie Spatiale

Pour la visualisation géographique, **GeoPandas** et **Shapely** ont été employés pour obtenir des cartes colorées

4. Les Données en Chiffres

2.05M

Tweets Analysés

Volume Total Analysé

1.140M

#DonaldTrump

Tweets pour Trump

910K

#JoeBiden

Tweets pour Biden

—

Période

Octobre 2020 - 3 novembre
2020

—


Couverture

51 États et territoires



Ces chiffres montrent l'ampleur du travail de nettoyage et d'analyse effectué.

5. Le Processus de Transformation des Données



6. Dévoilement des Sentiments sur Twitter




Analyse de la Polarité et de la Subjectivité


L'analyse des sentiments a révélé que la majorité des tweets étaient neutres, avec une polarisation modérée.

La polarité des tweets varie de -1 (très négatif) à +1 (très positif), avec 0 indiquant un sentiment neutre.

La subjectivité mesure si le tweet exprime un fait (0) ou une opinion (1).



Nuage de mots pour Donald Trump



Nuage de mots pour Joe Biden

7. Distribution des Sentiments : Chiffres Concrets

Analyse Comparative Trump vs Biden

Candidat	Positifs	Négatifs	Neutres	Polarité Moyenne
Trump	~35%	~25%	~40%	~0.05
Biden	~38%	~22%	~40%	~0.07

La distribution des sentiments est relativement équilibrée pour les deux candidats. Trump affiche une polarité légèrement plus faible (0.05) que Biden (0.07), indiquant une légère tendance positive pour Biden. Cependant, les deux candidats ont environ 40% de tweets neutres, ce qui montre une discussion politique modérée sur Twitter.

8. Corrélation entre les sentiments Twitter et les votes réels

$$m = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2}$$
$$b = \frac{\sum y - m \sum x}{n}$$

Méthodes issues du cours de statistiques : corrélation, régression linéaire, coefficient de détermination R^2 .



Objectif de l'analyse

Comparer la polarité moyenne des tweets par État avec les résultats électoraux réels pour voir si Twitter peut prédire le vote.

+ = x

Formule de la Régression Linéaire

J'utilise la régression linéaire pour trouver la meilleure droite reliant la polarité des tweets au pourcentage de votes par État.





Coefficient R^2

R^2 mesure le pourcentage de variation des votes expliqué par la polarité des tweets.

Plus R^2 est proche de 1, meilleure est la prédiction.

9. Scatterplots - Résultats de la Régression



Corrélations très faibles :

- Trump : $R^2 = 0.137 \rightarrow$ la polarité explique seulement 13,7% de la variance du vote.
- Biden : $R^2 = 0.026 \rightarrow$ quasi absence de lien entre polarité et vote.

La forte dispersion des points autour de la droite signifie des résidus importants, ce qui confirme la mauvaise qualité de l'ajustement (R^2 faible).

R^2 mesure la proportion de la variance du vote expliquée par la polarité des tweets.



10. Corrélations : Twitter et l'Urne

Corrélation Faible

$R^2 < 0.3$: Twitter ne constitue pas un indicateur fiable de l'intention de vote.

En statistiques, on considère généralement qu'un $R^2 > 0.5$ pour avoir une corrélation significative.

Le Sentiment n'est pas le Vote


Les sentiments exprimés en ligne ne prédisent pas efficacement les résultats électoraux.

11. Paysage des Sentiments : Une Perspective Géographique





Polarité Moyenne par État

Des cartes choroplèthes, générées avec **GeoPandas**, ont visualisé la polarité moyenne des tweets pour Trump et Biden dans chaque État. Bien qu'il y ait des variations, elles ne sont pas directement corrélées avec les résultats électoraux.



Subjectivité et Résultats Électoraux

Des cartes similaires ont été créées pour la subjectivité moyenne et les résultats officiels. J'ai observé des patterns géographiques partiellement cohérents, mais l'analyse de sentiment seule ne suffit pas pour la prédiction.



12. Twitter en Politique : Limites et Complémentarité



Biais Démographique

Utilisateurs non représentatifs de l'électorat.



Amplification Algorithmique

Contenus polarisants faussent la perception.



Bots et Manipulation

Fausse influence sur volume et tonalité.



Expression ≠ Action

L'expression en ligne n'est pas le vote.

Ce que Twitter Capture Réellement

- Énergie Émotionnelle : baromètre de l'intensité émotionnelle autour des campagnes.
- Patterns Géographiques : révèle des tendances géographiques dans la discussion politique.

Conclusion

Twitter doit être considéré comme un outil **complémentaire** pour comprendre les dynamiques politiques, mais **non prédictif** des résultats électoraux.

13. Leçons Apprises et Horizons Futurs

Compétences Acquises

Cette étude a permis de renforcer mes compétences en **Big Data** (gestion de 4.1M de tweets), en **NLP** (analyse des sentiments, nettoyage de texte), en **Régression Linéaire** (implémentation), et en **Cartographie Spatiale** (GeoPandas).

Axes d'Amélioration

Pour des recherches futures, il serait pertinent d'intégrer une **Analyse Temporelle** des tweets, d'explorer des modèles de **Machine Learning** plus avancés, et d'implémenter des méthodes de **Détection de Bots** pour affiner les données.

MERCI !

Des Questions ?

