

Corrélation Régression

1. Introduction

2. Coefficient de corrélation

Principe

Interprétation

3. Modèles de régression

Régression linéaire

Ajustement par un polynôme

Fonction exponentielle

Le coefficient de détermination

4. Approche non-paramétrique

Coefficient de corrélation de Spearman

Méthode et but

- 2 variables **numériques** (quantitatives)
- Identifier la nature des **variables** : *indépendante* x et *dépendante* y .
- Décrire la relation entre les variables
 - graphiquement
 - en utilisant une équation
- Utiliser l'équation pour prévoir une valeur y_i à partir d'une valeur x_i .
- Etablir le **degré de fiabilité** de l'estimation (relation probabiliste seulement)

La relation entre deux variables peut être :

- **déterministe** (Ceci ne nous concerne pas ici)
- **probabiliste** (C'est ce dont on va parler)

1. Introduction


Relation déterministe: La valeur de la variable y peut être précisément prédite à partir de la valeur de la variable x .

Exemples:

- Prix d'une maison et taxe due.
- Vitesse d'un corps en chute libre et temps.



$$V = V_0 + gt$$



1. Introduction

Relation probabiliste: La valeur d'une variable y ne peut pas être précisément prédite à partir de la valeur de la variable x - à cause d'autres facteurs.

Exemples:

1. Consommation en eau et une population

x = nombre d'habitants


y = eau consommée

2. Nombre d'heures passées à réviser un examen et la note obtenue.

x = heures passées à réviser

y = note obtenue


Regression possible avec une relation *probabiliste*.



2. Coefficient de corrélation

Le **coefficient de corrélation** ρ est une mesure du degré de corrélation linéaire. En pratique on essaye d'obtenir une estimation (r) à partir d'un échantillon représentatif de la population.

Approche géométrique:



2. Coefficient de corrélation


$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad \text{est un paramètre intéressant}$$

Évidemment cette somme dépend de n . On va donc diviser par $(n-1)$.
Au fait, pourquoi $(n-1)$ et pas simplement n ???

$$\text{Cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1} \quad \text{aussi appelée } s_{xy}$$

$\text{Cov}(x, y)$ est la covariance. Elle est utilisée dans de nombreuses méthodes multivariées.

Il y a encore un problème... La covariance dépend fortement des unités de x et de y .
Alors que faire...?



2. Coefficient de corrélation

Pour éviter ce problème on va diviser la covariance par l'écart type de x et l'écart type de y .

Coefficient de corrélation de Bravais-Pearson

$$r = \frac{\text{Cov}(x, y)}{s_x s_y} = \frac{s_{xy}}{s_x s_y}$$

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$


Un exemple...

2. Coefficient de corrélation

Numéro de l'essai i	Masse m_i x_i	Long. l_i y_i	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	2	42.0	-4.0	16.0	-9.3	86.9	37.28
2	4	48.4	-2.0	4.0	-2.9	8.5	5.84
3	6	51.3	0.0	0.0	0.0	0.0	0
4	8	56.3	2.0	4.0	5.0	24.8	9.96
5	10	58.6	4.0	16.0	7.3	53.0	29.12
n=5	$\bar{x} = 6$	$\bar{y} = 51.32$	$\sum = 0.0$	$\sum = 40$	$\sum = 0.0$	$\sum = 173.2$	$\sum = 82.2$

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} = \frac{82,2}{\sqrt{173,2 \times 40}} = 0,987$$

2. Coefficient de corrélation



2. Coefficient de corrélation


Allons un peu plus loin...

Inégalité de Schwarz:



$$|s_{xy}| \leq s_x s_y$$

Donc...


$$|r| \leq 1 \quad \text{ou} \quad -1 \leq r \leq 1$$



Liaisons absolues
(déterministe)



Liaison
stochastique
(probabiliste)



Pas de liaison

2. Coefficient de corrélation

Données : NEW.STA 10v * 21c				
VAL	1	2	3	4
TEX	BE	ZN	ZR	SR
1	1.710	175.700	62.043	395.100
2	1.910	96.027	71.500	528.036
3	1.984	45.141	68.403	458.670
4	1.740	44.399	61.248	486.010
5	1.873	34.403	64.161	493.880
6				
7	1.383	63.325	58.487	319.298
8	.988	42.956	30.329	284.497
9	1.129	24.452	39.551	415.797
10	1.646	29.746	64.706	284.576
11	2.263	37.094	71.469	162.895
12	1.720	30.472	63.137	385.542
13	1.770	31.772	67.092	391.498
14				
15	2.306	92.022	85.684	220.042
16	2.092	108.146	88.516	296.078
17	2.027	93.463	88.297	305.591
18	2.023	56.802	77.446	380.298
19	1.912	34.418	68.202	669.302
20				
21				

Etude des variables deux à deux

Un exemple:

Teneurs en Be, Zn et Sr (ppm)
dans l'étang de Thau


2. Coefficient de corrélation

La matrice de corrélation...

Corrélations (new.sta)				
Suite...	Corrélations significatives marquées à $p < .05000$ N=17 (Suppression des Observ. à VM)			
Variable	BE	ZN	ZR	SR
BE	1.00	.25	.91	-.09
ZN	.25	1.00	.38	-.13
ZR	.91	.38	1.00	-.13
SR	-.09	-.13	-.13	1.00

Représentation pratique pour l'exploration




2. Coefficient de corrélation



2. Coefficient de corrélation

En pratique attention!!!!!!



Ce coefficient de corrélation doit être manié avec grande précaution



- r donne le degré de liaison **linéaire**.
- Dépendance **curvilinéaire** forte et r faible dans le 2eme cas.
- Le diagramme xy doit donc **toujours être examiné** en même temps que la valeur de r .




2. Coefficient de corrélation

Le coefficient de corrélation peut produire de hautes valeurs si des **points isolés** sont présents.



2. Coefficient de corrélation

La corrélation de deux variables **log-transformées** doit toujours être interprétée avec précaution



2. Coefficient de corrélation

Au fait, à partir de quelle valeur de r peut-on considérer qu'on a vraisemblablement une corrélation??

0.6 ?

0.9 ?

0.4 ?



2. Coefficient de corrélation

Tests d'hypothèses

Population normale conjointe, hypothèse concernant la valeur de ρ

$$H_0 : \rho = 0 \text{ contre } H_1 : \rho \neq 0$$

Calcul de :

$$t_c = \frac{r \sqrt{n-2}}{\sqrt{1-r^2}}$$

On rejette H_0 si $t_c \geq t_{(\alpha/2, n-2)}$ ou si $t_c \leq -t_{(\alpha/2, n-2)}$

Remarque: un coefficient de corrélation $r = 0.4$ peut être significatif si $n = 100$ mais pas si $n = 10$.

2. Coefficient de corrélation

Exemple:

Les données Pb(ppm) vs. Zn (ppm) mesurées dans les sols du Derbyshire

(n=44) permettent de calculer un coefficient de corrélation $r = 0,765$.

Y-a-t 'il une corrélation significative entre Pb et Zn?

$$H_0: \rho = 0 \text{ contre } H_1: \rho \neq 0$$

Test :

$$t_c = \frac{r \sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0.765 \times \sqrt{44-2}}{\sqrt{1-0.765^2}} = 7.7$$

Pour $\alpha = 0.05$, t critique ≈ 2

t_c calculé $> t$ critique, donc H_0 est rejeté

Conclusion: Il y a une corrélation significative entre Pb et Zn

La régression

Une technique statistique pour analyser les relations qui existent parmi les variables.

Modèle de régression linéaire simple.

Equation linéaire décrivant la relation entre une simple variable **indépendante** x et une variable **dépendante** y

2. Analyse de regression

Estimer l'équation linéaire qui décrit le mieux la relation entre une variable **dépendante** (y) et une variable **indépendante** (x).


Exemple

- Un échantillon aléatoire de 15 appartements vendus à Dijon.
- Variables (pour chaque appartement):
- prix de vente (kF) et taille (m²).

Taille (m2)	Prix (kF)
20,0	225,2
70,4	725,9
20,5	296,0
etc	etc


2. Analyse de regression

- La relation linéaire apparaît positive mais elle n'est pas parfaite (**non déterministe**). Il y a un élément du au hasard.
- **Modèle probabiliste**, avec un terme d'erreur aléatoire qui va compter pour toutes les variables qui ne sont pas dans le modèle. (emplacement, présence de jardins...)



2. Analyse de regression – relation linéaire

- La droite qui s'ajuste le mieux aux données (*best fit*) est trouvée par la méthode aux **moindres carrés**. La méthode minimise la somme des carrés des distances verticales $|$ entre les points et la droite.



2. Analyse de regression – relation linéaire

$$y_i = ax_i + b + \varepsilon_i$$

y_i : variable dépendante

x_i : variable indépendante

b : intercept

a : pente

ε_i : erreur aléatoire

Ce sont des paramètres qui s'appliquent à l'équation s'ajustant le mieux à la population (x,y).

a et b sont les coefficients de la régression

Un brin de mathématiques...?



2. Analyse de regression – relation linéaire

Il faut minimiser ε_i

$$\varepsilon_i = y_i - b - ax_i$$

Plusieurs possibilités:

1. $\min_{a,b} \sum_i |\varepsilon_i|$

2. $\min_{a,b} \sum_i \varepsilon_i^2$

Le critère 2 correspond à la méthode aux *moindres carrés*.

Si l'on a n observations: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

et l'équation suivante liant les y_i aux x_i : $y_i = b + ax_i + \varepsilon_i$, $i = 1, \dots, n$

la somme des carrés des écarts à la droite est:

$$D = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - b - ax_i)^2$$

D doit être le plus petit possible... alors...?

2. Analyse de regression – relation linéaire

... dérivées partielles et on les pose égales à zéro.

$$D = \sum_{i=1}^n (y_i - b - ax_i)^2$$



$$\frac{\partial D}{\partial b} = -2 \sum_{i=1}^n (y_i - b - ax_i)$$


$$\frac{\partial D}{\partial a} = -2 \sum_{i=1}^n x_i (y_i - b - ax_i)$$

Les valeurs estimées de a et de b sont données par:

$$\sum_{i=1}^n (y_i - b - ax_i) = 0$$

$$\sum_{i=1}^n x_i (y_i - b - ax_i) = 0$$

ou bien ...



2. Analyse de regression – relation linéaire

$$\sum_{i=1}^n y_i - nb - a \sum_{i=1}^n x_i = 0$$

$$\sum_{i=1}^n x_i y_i - b \sum_{i=1}^n x_i - a \sum_{i=1}^n x_i^2 = 0$$

C'est-à-dire ...

$$\sum_{i=1}^n y_i = nb + a \sum_{i=1}^n x_i$$

$$\sum_{i=1}^n x_i y_i = b \sum_{i=1}^n x_i + a \sum_{i=1}^n x_i^2$$

D'autre part:

$$\bar{x} = \frac{x_1 + \dots + x_n}{n} = \sum_{i=1}^n \frac{x_i}{n} \quad \text{et}$$

$$\bar{y} = \frac{y_1 + \dots + y_n}{n} = \sum_{i=1}^n \frac{y_i}{n}$$




2. Analyse de regression – relation linéaire

$$a = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$
$$b = \frac{\sum y_i}{n} - a \frac{\sum x_i}{n} = \bar{y} - a \bar{x}$$

La droite de régression passe par $(\bar{x}; \bar{y})$

Ne nous énervons pas!!
En fait, ce n'est pas sorcier du tout...



Voyons plutôt un exemple.
Cas d'un ressort subissant un allongement sous l'effet d'un poids.

2. Analyse de regression – relation linéaire


Numéro de l'essai i	'X' Masse m_i	'Y' Longueur l_i	m_i^2	$m_i l_i$
1	2	42.0	4.0	84.0
2	4	48.4	16.0	193.6
3	6	51.3	36.0	307.8
4	8	56.3	64.0	450.4
5	10	58.6	100.0	586.0

$$n=5 \quad \sum m_i = 30 \quad \sum l_i = 256,5 \quad \sum m_i^2 = 220 \quad \sum m_i l_i = 1622$$

$$a = \frac{\sum m_i l_i - \frac{(\sum m_i)(\sum l_i)}{n}}{\sum m_i^2 - \frac{(\sum m_i)^2}{n}} = \frac{1622 - \frac{30 \times 256,5}{5}}{220 - \frac{900}{5}} = 2,055$$

$$b = \frac{\sum l_i}{n} - a \frac{\sum m_i}{n} = \frac{256,5}{5} - 2,055 \times \frac{30}{5} = 38,99$$

Statistiques



2. Analyse de regression – relation polynomiale

Y s'exprime comme polynôme d'une seconde variable X

$$y = a + bx + cx^2 + \dots + Hx^n$$

Exemple: la hauteur h de chute d'un corps est une fonction quadratique du temps t:

$$h = h_0 + v_0 t - \frac{1}{2} gt^2$$

On tire comme précédemment:

$$\sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i + c \sum_{i=1}^n x_i^2$$


$$\sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 + c \sum_{i=1}^n x_i^3$$

$$\sum_{i=1}^n x_i^2 y_i = a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i^3 + c \sum_{i=1}^n x_i^4$$

—————→ a, b, c

Ajustement polynômial par moindres carrés


2. Analyse de regression – Les autres grands modèles



2. Analyse de regression – Et les résidus...?


Attention

- Les **points isolés** ont un effet **indésirables** sur la régression
Leur influence doit être testée en les éliminant et en répétant la régression.
- La différence en y entre un point et la droite de régression est connue sous le nom de résidu.
La validité de la régression statistique dépend de la **distribution des résidus**:
 1. Les résidus doivent être **normalement** distribués
 2. Il ne doit pas y avoir de **tendance** dans la distribution de variance le long de x .




2. Analyse de régression – Et les résidus...?

Bande incurvée: Relation curvilinéaire. Ajouter des termes polynomiaux!




2. Analyse de regression – Et les résidus...?

Le fuseau: La variance des résidus n'est pas indépendante des valeurs de x . Des corrections doivent être apportées (courbe log. log p.e.)




2. Analyse de regression – Et les résidus...?




Bande oblique: Relation entre les résidus et la variable x . Si x n'est pas dans le modèle, il faudrait l'introduire, ou erreur importante.

2. Analyse de regression – Et les résidus...?



Bande horizontale: les conditions d'application sont suffisamment respectées

2. Analyse de regression – Le coefficient de détermination



2. Analyse de regression – Le coefficient de détermination

$$\sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2$$

Somme des carrés
totale (SC_{tot})

Somme des carrés
des résidus (SC_{res})

Somme des carrés
de la régression (SC_{reg})

Variation totale = variation inexpliquée + variation expliquée

$$R^2 = \text{Variation expliquée} / \text{variation totale}$$

R^2 est le **coefficient de détermination**, proportion de la variation de y qui s'explique par la présence de x .

Plus R^2 est grand, plus SC_{res} est petit.

3. Corrélations non-paramétriques – r_s de Spearman

Comme nous l'avons déjà vu, il est rare de trouver des variables normalement distribuées.

La corrélation paramétrique est donc particulièrement dangereuse car elle donne de forte corrélation en présence de points isolés.

En conséquence on utilisera plutôt une corrélation de rang.

Coefficient de rang de Spearman
- une méthode simple et populaire -

3. Corrélations non-paramétriques – r_s de Spearman

Echelle de la 1ere variable : ordinale

Echelle de la 2eme variable : ordinale

r_s : coefficient de rang (Spearman)

$$r_s = 1 - \frac{6 \sum_{i=1}^n D^2}{n(n^2 - 1)}$$

D représente, pour chaque observation, les différences de rang obtenues sur les deux variables.

3. Corrélations non-paramétriques – r_s de Spearman


Ech.	Be	Zr	Rang Be	Rang Zr	D*D
1	1,71	62,04	5	5	0
2	1,91	71,50	10	13	9
3	1,98	68,40	12	11	1
4	1,74	61,25	7	4	9
5	1,87	64,16	9	7	4
6	1,38	58,49	3	3	0
7	0,99	30,33	1	1	0
8	1,13	39,55	2	2	0
9	1,65	64,71	4	8	16
10	2,26	71,47	16	12	16
11	1,72	63,14	6	6	0
12	1,77	67,09	8	9	1
13	2,31	85,68	17	15	4
14	2,09	88,52	15	17	4
15	2,03	88,30	14	16	4
16	2,02	77,45	13	14	1
17	1,91	68,20	11	10	1
Somme					70

Un exemple

$$r_s = 1 - \frac{6 \sum_{i=1}^n D^2}{n(n^2 - 1)}$$

$$r_s = 1 - \frac{6 \times 70}{17 \times (17^2 - 1)}$$

$$r_s = 0.914$$



3. Corrélations non-paramétriques – r_s de Spearman

