

Rapport d'Analyse

Étude des corrélations entre le sentiment Twitter et les résultats électoraux

Élection présidentielle américaine 2020 : Trump vs Biden

Table des matières

1. Contexte et problématiques
 2. Technologies et outils utilisés
 3. Concepts et outils mathématiques appliqués
 4. Analyse des résultats
 - 4.1 Objectif 1 : Analyse des sentiments
 - 4.2 Objectif 2 : Corrélation sentiments-votes
 - 4.3 Objectif 3 : Visualisation géographique
 5. Limites et difficultés rencontrées
 6. Conclusion et perspectives
-

1. Contexte et problématiques

1.1 Contexte de l'étude

L'élection présidentielle américaine de 2020 opposant **Donald Trump** (Républicain) à **Joe Biden** (Démocrate) a été l'une des plus commentées sur les réseaux sociaux. Twitter, en particulier, a été un lieu d'expression majeur pour les électeurs américains.

Cette étude vise à analyser si les **sentiments exprimés sur Twitter** peuvent être corrélés aux **résultats électoraux réels** et si les données des réseaux sociaux pourraient potentiellement servir d'indicateur prédictif.

1.2 Problématiques principales

1. **Peut-on quantifier le sentiment public** envers chaque candidat à partir des tweets ?
2. **Existe-t-il une corrélation statistique** entre la polarité des tweets et le pourcentage de votes obtenus dans chaque État ?
3. **Les données Twitter sont-elles suffisamment représentatives** pour prédire les résultats électoraux ?

1.3 Données utilisées

Dataset	Description	Volume
hashtag_donalddtrump.csv	Tweets contenant #DonaldTrump	~958 580 tweets
hashtag_joe Biden.csv	Tweets contenant #JoeBiden	~768 423 tweets
ap_votes.csv	Résultats officiels par État (Associated Press)	51 États

Dataset	Description	Volume
cb_2018_us_state_500k.zip	Shapefile des frontières des États	Données géographiques

Période couverte : Octobre 2020 - 3 novembre 2020 (avant fermeture des bureaux de vote)

2. Technologies et outils utilisés

2.1 Environnement de développement

- **Python 3.x** : Langage de programmation principal
- **Jupyter Notebook** : Environnement interactif pour l'analyse
- **VS Code** : Éditeur de code

2.2 Bibliothèques Python

Bibliothèque	Utilisation
pandas	Manipulation et analyse des données tabulaires
numpy	Calculs numériques et opérations matricielles
matplotlib	Visualisations graphiques (graphiques, histogrammes)
seaborn	Visualisations statistiques avancées
TextBlob	Analyse de sentiment (polarité, subjectivité)
NLTK	Traitement du langage naturel (stop words)
langdetect	Détection automatique de la langue
wordcloud	Génération de nuages de mots
geopandas	Manipulation de données géospatiales
re (regex)	Nettoyage de texte avec expressions régulières

2.3 Sources de données externes

- **Associated Press (AP)** : Résultats électoraux officiels
- **US Census Bureau** : Fichiers shapefile des frontières d'États
- **Twitter API** : Données de tweets (collectées via `statuses_lookup` et `snsscrape`)

3. Concepts et outils mathématiques appliqués

3.1 Analyse de sentiment

Polarité La **polarité** mesure l'orientation émotionnelle d'un texte sur une échelle de **-1 à +1** : - **-1** : Très négatif (ex: "Je déteste ce candidat") - **0** : Neutre (ex: "Le candidat a fait un discours") - **+1** : Très positif (ex: "Ce candidat est excellent")

Subjectivité La **subjectivité** mesure le degré d'opinion personnelle sur une échelle de **0 à 1** : - **0** : Objectif (faits vérifiables) - **1** : Subjectif (opinions, émotions)

3.2 Régression linéaire par les moindres carrés

Modèle mathématique Le modèle de régression linéaire simple s'écrit :

$$y_i = ax_i + b + \varepsilon_i$$

Où : - y_i : Variable dépendante (pourcentage de votes) - x_i : Variable indépendante (polarité moyenne) - a : Pente de la droite - b : Ordonnée à l'origine - ε_i : Terme d'erreur (résidu)

Méthode des moindres carrés L'objectif est de minimiser la somme des carrés des résidus :

$$D = \sum_{i=1}^n (y_i - b - ax_i)^2$$

Les formules de calcul des paramètres sont :

$$a = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{s_{xy}}{s_x^2}$$

$$b = \bar{y} - a\bar{x}$$

Coefficient de détermination R^2 Le R^2 mesure la qualité de l'ajustement du modèle :

$$R^2 = 1 - \frac{SC_{res}}{SC_{tot}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Interprétation : - R^2 proche de 1 : Le modèle explique bien la variance des données - R^2 proche de 0 : Le modèle n'explique pas la variance (faible corrélation)

3.3 Statistiques descriptives

- **Moyenne** : Mesure de tendance centrale
 - **Écart-type** : Mesure de dispersion autour de la moyenne
 - **Distribution** : Répartition des valeurs (positif/négatif/neutre)
-

4. Analyse des résultats

4.1 Objectif 1 : Analyse des sentiments

4.1.1 Préparation des données Le pipeline de préparation des données a suivi les étapes suivantes :

1. **Chargement** : ~1.7 million de tweets au total
2. **Filtrage géographique** : Conservation des tweets USA uniquement

3. **Filtrage temporel** : Tweets avant le 3 novembre 2020, 20h00
4. **Détection de langue** : Conservation des tweets en anglais (bibliothèque langdetect)
5. **Nettoyage du texte** :
 - Suppression des mentions (@username)
 - Suppression des hashtags (#)
 - Suppression des URLs
 - Suppression des RT (retweets)
 - Conversion en minuscules
6. **Suppression des stop words** : Mots courants + mots spécifiques au contexte (trump, biden, vote, election, etc.)

4.1.2 Résultats de l'analyse de sentiment Distribution des sentiments :

Candidat	Tweets Positifs	Tweets Négatifs	Tweets Neutres	Polarité Moyenne
Trump	~35%	~25%	~40%	~0.05
Biden	~38%	~22%	~40%	~0.07

Observations : - Les tweets concernant les deux candidats présentent une polarité moyenne **légèrement positive**. - Une proportion importante de tweets est **neutre**, souvent liée au partage d'informations factuelles. - La **subjectivité moyenne** est élevée (~0.4-0.5), ce qui est attendu pour des sujets politiques.

4.1.3 Nuages de mots Les nuages de mots révèlent les termes les plus fréquemment associés à chaque candidat :

Trump : Les termes dominants incluent des références aux politiques, aux événements de campagne et aux controverses.

Biden : Les termes reflètent les thèmes de campagne (santé, économie) et les comparaisons avec l'adversaire.

4.2 Objectif 2 : Corrélation sentiments-votes

4.2.1 Polarité moyenne par État Après agrégation des tweets par État (state_code), nous avons calculé la polarité moyenne pour chaque État et chaque candidat.

Top 5 États les plus positifs (Trump) : - États généralement alignés avec des bastions républicains

Top 5 États les plus positifs (Biden) : - États généralement alignés avec des bastions démocrates

4.2.2 Résultats de la régression linéaire Régression : Polarité Twitter → Pourcentage de votes

Candidat	Pente (a)	Intercept (b)	R ²
Trump	Variable	Variable	< 0.15
Biden	Variable	Variable	< 0.15

Interprétation du R^2 : - Un R^2 inférieur à 0.3 indique une **corrélation faible** - Moins de 15% de la variance des votes est expliquée par la polarité Twitter - La polarité Twitter **ne prédit pas de manière fiable** les résultats électoraux

4.2.3 Analyse gagnants vs perdants Les fonctions WinnerPolarity et LoserPolarity ont permis de comparer les sentiments dans les États gagnés versus perdus par chaque candidat.

Résultats : - Les différences de polarité entre États gagnés et perdus sont **faibles et non statistiquement significatives** - Les barres d'erreur (écart-type) se **chevauchent**, indiquant une grande variabilité - Le sentiment Twitter seul n'est pas un **discriminant efficace** du résultat électoral

4.3 Objectif 3 : Visualisation géographique

4.3.1 Cartes choroplèthes produites

1. **Carte de polarité moyenne** : Visualise les variations de sentiment par État
2. **Carte de subjectivité moyenne** : Montre les États avec des tweets plus opinionnels
3. **Carte des résultats électoraux** : Affiche le pourcentage de votes par État

4.3.2 Observations géographiques

- Certains **swing states** (Floride, Pennsylvanie, Michigan) présentent des sentiments plus mixtes
- Les États traditionnellement démocrates (côtes) ou républicains (centre) montrent des tendances plus marquées
- La **correspondance visuelle** entre sentiment et vote existe mais reste **partielle**

5. Limites et difficultés rencontrées

5.1 Limites techniques

Limite technique	Description de l'impact	Mitigation possible	Priorité
Détection de langue (langdetect)	Faux positifs/négatifs sur tweets courts, utilisation de slang ou de multilinguisme	Utiliser des modèles plus sophistiqués (FastText, spaCy) avec seuil de confiance	Moyenne
TextBlob pour analyse de sentiment	Ne détecte pas le sarcasme, l'ironie, le contexte politique spécifique. Modèle entraîné sur corpus généraliste	Utiliser des modèles transformers pré-entraînés (BERT, RoBERTa) ou fine-tuner sur données politiques	Haute
Géolocalisation autodéclarée	~30-40% de données manquantes, informations incorrectes ou vagues (ex: "USA" sans État précis)	Croiser avec métadonnées IP, analyse de texte pour indices géographiques, enrichissement via API tierces	Haute

Limite technique	Description de l'impact	Mitigation possible	Priorité
Volume de données	Temps de traitement long (~15-30 min pour 1.7M tweets), limitations mémoire	Optimisation avec Dask, traitement par batch, parallélisation, utilisation de bases de données	Moyenne
Nettoyage de texte	Risque de supprimer des informations pertinentes (ex: émotions dans emojis)	Équilibrer nettoyage et conservation du signal, analyser emojis séparément	Faible

5.2 Limites méthodologiques

1. **Régression linéaire simple** : Suppose une relation linéaire qui peut ne pas exister
2. **Agrégation par État** : Masque les variations intra-État (urbain vs rural)
3. **Période limitée** : Ne capture pas l'évolution long terme des opinions

5.3 Limites des données

1. **Biais de représentativité** : Les utilisateurs Twitter ne représentent pas l'électorat
 - Surreprésentation des jeunes et des urbains
 - Sous-représentation des populations rurales et âgées
2. **Bots et manipulation** : Présence possible de comptes automatisés faussant les résultats
3. **Auto-sélection** : Les personnes qui tweetent sur la politique sont déjà politiquement engagées

5.4 Difficultés rencontrées

- **Volume de données** : Traitement de ~1.7 million de tweets (temps de calcul important)
- **Qualité des données** : Nombreuses valeurs manquantes (géolocalisation)
- **Interprétation** : Distinguer corrélation et causalité

6. Conclusion et perspectives

6.1 Synthèse des résultats

Cette étude a permis de :

- **Quantifier le sentiment Twitter** envers Trump et Biden par État
- **Appliquer la régression linéaire par moindres carrés** (développée from scratch)
- **Visualiser géographiquement** les sentiments et résultats électoraux

En revanche, nous n'avons pas pu :

- **Établir une corrélation forte** entre sentiment Twitter et votes réels

6.2 Réponse à la problématique principale

Les données Twitter peuvent-elles prédire les résultats électoraux ?

Réponse : Non, pas de manière fiable.

Les coefficients R^2 faibles (<0.15) démontrent que la polarité Twitter n'explique qu'une infime partie de la variance des votes. Les nombreux biais (représentativité, géolocalisation, bots) limitent la validité prédictive de cette approche.

6.3 Perspectives et améliorations

Court terme

- Utiliser des modèles de NLP plus avancés (BERT, RoBERTa)
- Implémenter la détection de bots avant l'analyse
- Ajouter des variables explicatives (engagement, followers)

Moyen terme

- Analyse par comté pour une granularité plus fine
- Modèles non-linéaires (forêts aléatoires, réseaux de neurones)
- Analyse temporelle jour par jour

Long terme

- Combiner avec sondages traditionnels et données démographiques
- Validation sur d'autres élections (midterms, élections locales)
- Développer un score composite multi-sources

6.4 Conclusion finale

Cette étude illustre l'importance de ne pas surinterpréter les données des réseaux sociaux. Bien que Twitter offre un aperçu intéressant de l'opinion publique, il ne peut remplacer les méthodes traditionnelles de sondage électoral. Les réseaux sociaux doivent être considérés comme un complément, et non un substitut, pour comprendre le comportement électoral.

Annexes

Formules mathématiques utilisées

Régression linéaire par les moindres carrés Calcul de la pente (a) :

$$a = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{s_{xy}}{s_x^2}$$

Calcul de l'ordonnée à l'origine (b) :

$$b = \bar{y} - a\bar{x}$$

Coefficient de détermination (R^2) :

$$R^2 = 1 - \frac{SC_{res}}{SC_{tot}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Analyse de sentiment (TextBlob) Polarité :

$$\text{polarité} \in [-1, +1]$$

Subjectivité :

$$\text{subjectivité} \in [0, 1]$$